



# 基于 NSCT-SF-PCNN 图像融合算法实现

王欢

学号: 181499

指导教师: 金立左

东南大学自动化学院

August 22, 2019



# 目录

## 引言

## NSCT 的图像融合方法

## 基于脉冲耦合神经网络的图像融合算法

## 基于 NSCT-SF-PCNN 的图像融合算法



# 目录

## 引言

### NSCT 的图像融合方法

### 基于脉冲耦合神经网络的图像融合算法

### 基于 NSCT-SF-PCNN 的图像融合算法



# 引言

## 研究背景

- 多传感器图像融合
- 多焦点图像融合
- 时间序列图像融合

## 主要工作

- 多源图像配准
- 图像特征分解
- 图像重构



# 目录

引言

**NSCT 的图像融合方法**

基于脉冲耦合神经网络的图像融合算法

基于 NSCT-SF-PCNN 的图像融合算法

# 图像融合中的 Contourlet 理论

Contourlet 变换是利用拉普拉斯金字塔 (LP) 变换和方向滤波器组 (Directional Filter Bank, DFB) 实现的一种图像多尺度几何分析工具, 它不仅具有多分辨率和时频局部性的特点, 还具有高度的方向性和各向异性。Contourlet 变换将多尺度分析和方向分析分开进行, 分解为 LP 分解和 DFB 滤波两个过程, 重构则是上述两个过程的逆过程。

LP 首先用于捕获点不连续性, 然后是 DFB, 以将点不连续性链接到线性结构。相较于小波变换, Contourlet 的灵活性体现在每层分解方向数量可以不同。不幸的是, 原始 Contourlet 变换的 LP 和 DFB 中都存在下采样操作 (如右图所示), 因此在进行平移变换时, 容易产生**频谱混叠现象**。




图 1: Contourlet

# NSCT

为克服 Contourlet 的频谱混叠缺点, Cunha 等人提出的非下采样 Contourlet 变换 (NSCT) 属于完全冗余 Contourlet 变换 (如右图所示), 即塔式变换和方向变换均冗余, 它利用非下采样金字塔 (Nonsubsampled Pyramid, NSP) 变换和非下采样方向滤波器组 (Nonsubsampled Directional Filter Bank, NSDFB) 构造, 具有完全平移不变性, 且图像经 NSCT 分解后得到的各子带系数的尺寸大小与源图像是相同的, 这有利于图像融合时融合规则的制定。与 Contourlet 变换类似, NSCT 同样将多尺度分析和方向分析分开进行。




图 2: Contourlet

# 非下采样金字塔 (NSP) 变换

NSP 采用的是一组二维的双通道非下采样滤波器组 (Nonsubsampled Filter Bank, NSF), 实现一个类似于 Contourlet 变换中 LP 变换的子带分解。使用 NSP 对图像进行分解时, 在每一级 NSP 分解后, 都需要用矩阵  $2I$  对滤波器进行填零上采样, 作为下一级分解的滤波器, 其中  $I$  为 2 阶单位矩阵。右图展示了图像经 3 级 NSP 分解的过程, 其中  $y_0$  为低频子带,  $y_1$ 、 $y_2$ 、 $y_3$  为高频子带, 浅灰色区域为上采样造成的混叠, 从图中可以看出各子带图像具有相同的尺寸大小。




图 3: NSP 分解示意图



# 非下采样方向滤波器组 (NSDFB)

NSDFB 采用的同样也是一组二维的双通道 NSFB。NSDFB 对图像进行树形结构分解，在每一级方向分解后，都需要用一个梅花采样矩阵对 DFB 中的所有滤波器进行填零上采样，作为下一级方向分解的 DFB。右图展示了一个四通道的 NSDFB 的结构，它由两个双通道扇形 QFB 经过填零上采样操作得到。




图 4: 四通道 NSDFB

# 由 NSP 和 NSDFB 构建 NSCT

将 NSP 和 NSDFB 结合起来就可以构造 NSCT。






图 5: 构建 NSCT 所采用的 NSFB 结构

# NSCT 中消除频谱混叠现象



(a)



(b)

在构建 NSCT 时，由于 NSDFB 树状结构的特性，对 NSP 分解得到的高频子带使用 NSDFB 时，在较低和较高频率上的方向响应存在混叠，如图 (a) 所示，在方向滤波器的通带区域上标注了“Good”或“Bad”，较粗尺度下的高通通道将被方向滤波器中的“Bad”通带区域过滤掉，这使得丢失大量的方向信息，导致图像严重走样。如果适当地对 NSDFB 上采样处理，就能将“Good”通带区域覆盖到高通通道上，如图 (b) 所示。

# NSP 和 NSDFB 完全重构的条件




图 6: 塔形 NSFB




图 7: 扇形 NSFB

并且必须满足如下式所示的 Bezout 恒等式，才能保证 NSP 和 NSDFB 是完全重构的，继而保证 NSCT 是完全重构的。

$$H_0(z)G_0(z) + H_1(z)G_1(z) = 1$$

$$U_0(z)V_0(z) + U_1(z)V_1(z) = 1$$

# NSCT 分解结果

以 Zoneplate 作为输入图像 (如右图所示), 经两层 NSP 变换分解, 尺度从细到粗的方向分解级数分别为 1、2。




图 8: Zoneplate 原始图像

# NSCT 分解结果




图 9: 低频子带




图 10: 第 1 层高频方向子带




图 11: 第 2 层高频方向子带



# 目录

引言

NSCT 的图像融合方法

**基于脉冲耦合神经网络的图像融合算法**

基于 NSCT-SF-PCNN 的图像融合算法



# PCNN 简化模型

由于原始 PCNN 模型较为复杂，且模型参数物理意义并不明确，因此实际使用时模型经过简化。其中， $\otimes$  为卷积运算， $\oplus$  为加法运算， $i, j$  为神经元标号，其连接范围为  $k, l$ ， $S$  为神经元外部激励，本文中即图像灰度值，直接作为神经元的反馈输入  $F$ ， $L$  为神经元连接输入，其连接矩阵、放大系数和衰减时间系数分别为  $W$ 、 $V_L$  和  $\alpha_L$ ， $U$  为神经元内部活动项，其连接强度系数为  $\beta$ ， $\theta$  为动态门限，其放大系数和衰减时间系数分别为  $V_\theta$  和  $\alpha_\theta$ ， $Y$  为神经元输出，当  $U > \theta$  时产生一次输出。

$$F_{ij}(n) = S_{ij}$$

$$L_{ij}(n) = e^{-\alpha_L} L_{ij}(n-1) + V_L \sum_{kl} W_{ij,kl} Y_{kl}(n-1)$$

$$U_{ij}(n) = F_{ij}(n)(1 + \beta L_{ij}(n))$$

$$\Theta_{ij}(n) = e^{-\alpha_\theta} \Theta_{ij}(n-1) + V_\theta Y_{ij}(n-1)$$

$$Y_{ij}(n) = \begin{cases} 1, & U_{ij}(n) \geq \Theta_{ij}(n) \\ 0, & U_{ij}(n) < \Theta_{ij}(n) \end{cases}$$



# PCNN 简化示意图




图 12: PCNN 神经元简化模型





图 13: PCNN 图像处理示意图



# PCNN 工作原理

PCNN 图像融合流程如图所示。根据 PCNN 工作原理可知，经过一定次数迭代过后可得双源图像点火映射图，通过判决选择算子计算融合图像系数，进而融合图像。





# 算子选择

当 PCNN 模型确定后，只需确定判决选择算子，设双源图像  $A$  和  $B$  的  $n$  次点火映射图分别为  $T_{ij}^A(n)$  和  $T_{ij}^B(n)$ ，融合图像为  $F$ ， $I_{ij}$  为图像  $(i, j)$  处像素灰度值，则有：

$$I_{ij}^F = \begin{cases} I_{ij}^A, & T_{ij}^A(n) \geq T_{ij}^B(n) \\ I_{ij}^B, & T_{ij}^A(n) < T_{ij}^B(n) \end{cases}$$



# 目录

引言


NSCT 的图像融合方法

基于脉冲耦合神经网络的图像融合算法

**基于 NSCT-SF-PCNN 的图像融合算法**

# NSCT-SF-PCNN 算法框架

PCNN 用于图像融合的核心原因在于其神经元的全局耦合和脉冲同步。这些生物特征充分利用了图像中的局部信息，而不是大多数流行的基于 MSD 的融合算法中的单一系数信息。尽管在多焦点图像融合中研究了 PCNN 的区域点火特性，但仍然使用点火时间作为选择 NSCT 系数的确定。



# NSCT-SF-PCNN 算法实现

- ① Decompose the source images into subbands via NSCT.
- ② Measure the SF as (1) in slipping window of coefficients in subbands.
- ③ SF in each subbands are input to PCNN to motivate the neurons and generate pulse of neurons with (2). Then, firing times  $T_{ij}^{l,k}(n)$  is calculated as (3).
- ④ Get the decision map  $D_{ij}^{l,k}$  based on (4) and select the coefficients with (5), which means that coefficients with large firing times are selected as coefficients of the fused image.

$$D_{F,ij}^{l,k} = \begin{cases} 1 & T_{1,ij}^{l,k}(n) \geq T_{2,ij}^{l,k}(n) \\ 0 & T_{1,ij}^{l,k}(n) < T_{2,ij}^{l,k}(n) \end{cases} \quad (1)$$

$$x_{F,ij}^{l,k} = \begin{cases} x_{1,ij}^{l,k} & D_{ij}^{l,k}(n) = 1 \\ x_{2,ij}^{l,k} & D_{ij}^{l,k}(n) = 0 \end{cases} \quad (2)$$

where  $x_{F,ij}^{l,k}$ ,  $x_{1,ij}^{l,k}$  and  $x_{2,ij}^{l,k}$  denote the coefficients of the fused image and two source images, respectively.

- ⑤ Use the selected-out coefficients in (5) to reconstruct the fused image via inverse NSCT.



# NSCT-SF-PCNN 算法 Matlab 实现

NSCT 的具体参数为  $[0, 1, 3, 4, 4]$ 。PCNN 具体参数为： $\alpha_L = 0.06931$ ,  
 $\alpha_\theta = 0.2$ ,  $\beta = 0.2$ ,  $V_L = 1.0$ ,  $V_\theta = 20$ ,  $W = \begin{bmatrix} 0.707 & 1 & 0.707 \\ 1 & 0 & 1 \\ 0.707 & 1 & 0.707 \end{bmatrix}$ , 最  
大迭代数为  $n = 200$ .

# NSCT-SF-PCNN 算法融合效果



(a) clock 右聚焦原图



(b) clock 左聚焦原图



(c) DWT



(d) SWT



(e) NSCT



(f) NSCT-SF-PCNN



(g) 图 (c) 局部放大



(h) 图 (d) 局部放大



(i) 图 (e) 局部放大



(j) 图 (f) 局部放大





# 结果分析

- ① 基于 NSCT-SF-PCNN 的图像融合算法有效地保留了左聚焦图像和右聚焦图像中的目标信息
- ② SWT 和 NSCT 分解时都没有下采样环节, 使得变换都具有平移不变性, 从而避免了伪 Gibbs 现象的出现
- ③ NSCT 在方向分解上比 SWT 能获得更多的高频方向子带, 捕获图像边缘的能力更强
- ④ 使用 NSCT 与 PCNN 结合的图像融合方法, 不但能捕获更多的边缘信息, 而且能增强图像的对比度, 使图像的边缘更加尖锐轮廓更加清晰, 其中使用本文方法的融合图像最为明显

## 总结

基于 NSCT-SF-PCNN 的融合方法, 不但能有效地融合多聚焦图像中的目标信息, 还能增强图像的对比度, 更好地区分图像中的目标信息和背景信息。



Thanks for Listening.